

Jev 1.13.0 域校准实测报告

自报置信 vs 实际能力: 七域扫描

Nautilus Assay(伊洛科技有限公司)

独立验证 • 工件全公开可复算

2026 年 9 月 26 日

摘要

我们在自己的七个任务域上实测了 Jev 1.13.0(hosted) 标榜的 “calibrated confidence”。核心读数: 在合成邮件三分类任务上,Jev 自报平均置信 **91%**, 实际选择题准确率 **50%**——校准分 $C = 1 - \text{ECE}$ 仅 **0.086**。规律: 域越模糊、越接近业务现场 (分诊/标注/行为判断), 校准崩塌越严重; 闭合式任务上校准良好。全部原始工件与判分程序公开, 任何人可复算; 我们自家系统在同一面墙上以同一把尺照登。

1 方法

测量仪器:jev-trust(MIT 开源,`pip install jev-trust`), 校准货币 $C(\text{agent}, \text{domain}, t) = 1 - \text{ECE}_t$, top-label 口径,10 桶分箱。每域 $n=120$ (标注类) 或按任务定义; hosted API 全量调用, 原始应答留痕。判分与 ECE 计算脚本公开, 非实现者复算流程内置。

2 七域读数

3 解读

- 校准崩塌发生在业务现场。三分类分诊是最常见的生产决策形态 (路由/审核/过滤), 恰恰在此自报置信 91% 而准确率 50%——置信虚高直接转化为错单、漏检、误放行。
- 闭合域可信。闭合确定性任务与对抗压测的 $C \geq 0.959$, 说明问题不在模型能力, 在置信度对域的迁移没有随域重新校准。
- 操作结论:Jev 是快而省的决策引擎 (TypeSafe 官方宣称 40–200× 快/40–400× 便宜, 非本文测量), 但在你的域里, 其置信度应先实测再使用——典型修正如「0.9 当 0.77 用」。

域	准确率	自报置信	C (1-ECE)
闭合确定性任务	—	—	0.959
对抗压测	—	—	0.988
Python 异常预测	100%	—	0.953
代码 patch 行为判定	92.5%	—	0.866
具身数据 QC 标注 [†]	50%(全 yes 策略)	—	0.689
邮件分诊 (布尔 spam)	—	—	0.831
邮件三分类 (choice)	50%	91%	0.086
NanoJev 0.6B(本地) 轨迹重放	—	—	≈1.000
NanoJev 0.6B 校准基准重放	—	—	≈1.000

表 1: [†] 全 yes 策略 = 对所有样本一律答 yes: 召回 100%、精确率 50%——模型在模糊域退化为一键策略但置信度仍高。

4 诚实披露

- 第 3–5 行读数待第二操作员独立复算 (验证墙目录中已标注); 其余为单轮测量。
- 我们自家记忆系统 (NautilusMem) 在同一验证墙挂 **UNVERIFIED**——同一把尺, 先量自己。
- 本报告只覆盖我们实测的校准维度; 不涉及安全性、延迟、成本等未测维度。

5 可验证性

- 验证墙 (签名成绩单 + 方法论, 实时): https://github.com/chunxiaox/nautilus-compass/blob/main/docs/wall/MEMORY_SYSTEMS_DIRECTORY.md
- 测量仪器 (MIT): <https://pypi.org/project/jev-trust/>
- Trust Report #1: https://compass.nautilus.social/trust_report_2026-09.html

如果你的生产环境在跑 Jev

给我们 20–50 条你的真实决策样本, 48 小时内交付带 ed25519 签名的域校准报告 (DCR): 你域上的真实准确率、校准误差、与通用基线的偏移, 以及一句可操作的话——「你的域里 0.9 的置信当 0.77 用」。全原始工件随附, 任何人可复算; 判错赔付条款 (§5b) 适用。