

Don't Summarize the Past for a Future You Can't Predict

nautilus-compass · agent memory

Chunxiao Wang · 2026-09 · github.com/chunxiaox/nautilus-compass

0

写入 LLM 调用


42.6 → 75.4%

e2e · LongMemEval-S 500 题

80×

p95 延迟优势
亚秒 vs 26.9s

你的 agent 正在忘记你




市场现状:三大策略,同一个死穴


策略	谁在做	何时做有损决定
压缩	多数 SaaS 记忆层	写入时
提炼/摘要	mem0 / Zep / Letta	写入时
裸读长上下文	直塞 context window	牺牲性能(掉 30-60%)

全部在写入时对未来下注 —— 没有人把宝押在读取端

反架构:写入零智能,读取全智能



三不变量:为什么写入时压缩必输



未来查询不可知 · 原文唯一可重索引 · 成本曲线方向反了 —— 写入免费是自然结果,不是优化奇迹

读取端四件套


读取端四件套:e2e 42.6% → 75.4% 的全部来源




同样公开的负结果(预注册否决):

rerank 有害(-2pt) · K=50 无增益 · 小 embedder 更差


e2e 主战场:42.6 → 75.4




六分型成绩单




同题同判据对打




客场作战:第三方榜单



官方基准 LME-V2:双域翻倍



延迟:80× 差距从哪来



判分卫生学:我们抓了自己判官 5 次

判分卫生学:我们抓了自己判官 5 次

判官会静默失败 —— 不抓,你的排行榜就是虚构的

× 网关断连

71 题被静默记成错答
= 整卷 14.2%

× 401 变量名坑

harness 默认读 OPENAI API KEY
source ARK 变量 = 全员 401

× 预算被吃满

judge 4096 token 被
reasoning 吃满 → 系统性压 0

× 并发写文件

双进程同写一文件
结果互相覆盖

→ 协议:预注册锚 • 冒烟测试 • 双口径 • Wilson CI

预注册文化:否决自己也是产出


- LoRA 检索增强:代理指标涨,端到端平 → 关闭
- abstention gate:误拒答 92/89 题($\text{门} \leq 1/\leq 2$) → 预注册拒收
- cheap-tier 三改组合:双域未超现役 → 关闭

拒绝噪声改进,和拿到提升一样,是结果

我们自己的组织跑在上面



跨会话记忆(现场 live)



```
terminal - nautilus-compass (fully local)

$ compass ingest --session s1 "用户周二早上遛狗,狗叫 Momo"
  ✓ stored verbatim · 0 LLM calls · 0.3s
$ compass ingest --session s2 "在学 Rust,目标重写公司数据处理管线"
  ✓ stored verbatim · 0 LLM calls
$ compass ingest --session s3 "每周一例会总被临时取消"
  ✓ stored verbatim · 0 LLM calls

# —— 三周后 · 全新会话 ——
$ compass recall "What does the user do on Tuesday mornings?"
  → session-1: "周二早上遛狗,狗叫 Momo" score 0.89
  ✓ cross-session hit · routed retrieval · p95 0.34s

$ compass recall --session # control: 全新空记忆,同一问题, (empty)
```

demo 流程示意(与 demo_recording_script.md 同源,现场跑真实终端)

三档接入,一个承诺

路径	适合谁	成本
本地三条命令	隐私/成本敏感 · 单机 agent	永久免费,数据不出机器
Hosted beta	快速试用 · 团队	compass.nautilus.social 自助 signup
私有化	组织部署	联系我们

- 写入 0 token · 召回 0 上云 · BGE-m3 本地嵌入
- Modified MIT:自部署/内部/个人永久免费

开放程度用行为定义:全源码 + \$3.50 复现 + 证据链全公开

接入(30 秒版)

```
git clone https://github.com/chunxiaox/nautilus-compass \
  ~/.claude/plugins/nautilus-compass
bash ~/.claude/plugins/nautilus-compass/install.sh
bash ~/.claude/plugins/nautilus-compass/daemon_start.sh
```

不想本地跑:compass.nautilus.social · 自助 signup → scoped token → 任意 MCP 客户端

One developer. 130 days. No cloud required.

(备用页)常问问题

mem0 自报 94.4% vs 你们 75.4%? 口径不同不可比;硬对打=同题同判据检索层 +11.6pt

Modified MIT 是什么? MIT + 商标保护 + 托管规模上限;自部署/内部/个人永久免费

多租户谁验证的? 四探针脚本开源,任何人对生产端点可重跑

为什么不是纯开源? 全源码可得 + \$3.50 复现全链路 + 证据链全公开——开放程度用行为定义,不用标签