

Don't Summarize the Past for a Future You Can't Predict

nautilus-compass · agent memory

Chunxiao Wang · 2026-09

github.com/chunxiaox/nautilus-compass

写入 0 LLM 调用 · e2e 42.6% → 75.4% · p95 快 80×

你的 agent 正在忘记你

写入时压缩 = 对未来的盲目下注

压缩写入时刻
提炼在此发生
信息被冻结在当初那个
模型的认知水平

未来查询
没人知道会被问什么
分布不可知
(今天赌不中明天的题)

× 赌注在结构上就赢不了

而且成本曲线方向反了

存储 → 0

LLM 调用恒贵

把便宜的换成昂贵的 = 双输

市场现状:三大策略,同一个死穴

策略	谁在做	何时做有损决定
压缩	多数 SaaS 记忆层	写入时
提炼/摘要	mem0 / Zep / Letta	写入时
裸读长上下文	直塞 context window	牺牲性能(掉 30-60%)

全部在写入时对未来下注 —— 没有人把宝押在读取端

反架构:写入零智能,读取全智能


nautilus-compass • 反架构:写入零智能,读取全智能

治理

drift 检测(AUC 0.83)· 合约审计 · scoped 多租户 · 判分卫生学

进化


跨 agent 记忆胶囊:验证后写回(reward ≥ 1.0 防毒门)→ 按需继承



写入:免费、无损、永远 —— 智能全部在读取端

三不变量(为什么写入时压缩必输)

成本曲线方向反了:行业默认把智能放在最贵的那一端



读取端四件套

读取端四件套:e2e 42.6% → 75.4% 的全部来源




同样公开的负结果(预注册否决):

rerank 有害(-2pt) · K=50 无增益 · 小 embedder 更差


证据 ①:e2e 主战场

同样的记忆,同样的题 —— 变的只是读取端路由




证据 ②:六分型成绩单

六分型成绩单:哪里强、哪里是下一步(tr 62.4 = 已知短板,不藏)




证据 ③:同题同判据对打

唯一站得住的对打:同 500 题 • 同判据 • BGE-m3 双方




证据 ④:客场作战

客场作战:第三方 EverMemBench 榜单口径



证据 ⑤:官方基准 LME-V2



延迟:80× 差距从哪来

p95 延迟 $\approx 80\times$ 差距:把智能放对时刻的自然结果

nautilus-compass
(读取端路由,无 LLM)

$\approx 80\times$

26.9 s

LLM-controller 型
(写入时压缩阵营)

10^{-1}

10^0

10^1

10^2

判分卫生学:我们抓了自己判官 5 次

判分卫生学:我们抓了自己判官 5 次

判官会静默失败 —— 不抓,你的排行榜就是虚构的

× 网关断连

71 题被静默记成错答
= 整卷 14.2%

× 401 变量名坑

harness 默认读 OPENAI_API_KEY
source ARK 变量 = 全员 401

× 预算被吃满

judge 4096 token 被
reasoning 吃满 → 系统性压 0

× 并发写文件

双进程同写一文件
结果互相覆盖

→ 协议:预注册锚 · 冒烟测试 · 双口径 · Wilson CI

预注册文化:否决自己也是产出

- LoRA 检索增强:代理指标涨,端到端平 → 关闭
- abstention gate:误拒答 92/89 题 → 预注册拒收
- cheap-tier 三改组合:双域未超现役 → 关闭

拒绝噪声改进,和拿到提升一样,是结果

dogfood:我们自己的组织跑在上面

dogfood:造它的组织,本身就长在它上面

130


天

771

commits

603

由 agent 舰队提交



nautilus 智涌平台:多 agent 调度 · compass 记忆胶囊:验证过的经验才写回

Demo:跨会话记忆(现场 live)

```
terminal - nautilus-compass (fully local)

$ compass ingest --session s1          "用户周二早上遛狗,狗叫 Momo"
  ✓ stored verbatim · 0 LLM calls · 0.3s

$ compass ingest --session s2          "在学 Rust,目标重写公司数据处理管线"
  ✓ stored verbatim · 0 LLM calls

$ compass ingest --session s3          "每周一例会总被临时取消"
  ✓ stored verbatim · 0 LLM calls

# —— 三周后 · 全新会话 ——
$ compass recall      "What does the user do on Tuesday mornings?"
  → session-1: "周二早上遛狗,狗叫 Momo"      score 0.89
  ✓ cross-session hit · routed retrieval · p95 0.34s
```


三档接入,一个承诺

路径	适合谁	成本
本地三条命令	隐私/成本敏感 · 单机 agent	永久免费,数据不出机器
Hosted beta	快速试用 · 团队	compass.nautilus.social 自助 signup
私有化	组织部署	联系我们

- 写入 0 token · 召回 0 上云 · BGE-m3 本地嵌入
- Modified MIT:自部署/内部/个人永久免费

接入(30 秒版)

```
git clone https://github.com/chunxiaox/nautilus-compass \
  ~/.claude/plugins/nautilus-compass
bash ~/.claude/plugins/nautilus-compass/install.sh
bash ~/.claude/plugins/nautilus-compass/daemon_start.sh
```

不想本地跑:compass.nautilus.social · 自助 signup → scoped token → 任意 MCP 客户端

One developer. 130 days. No cloud required.

(备用页)常问问题

- **mem0 自报 94.4% vs 你们 75.4%?** 口径不同不可比;硬对打=同题同判据检索层 +11.6pt
- **Modified MIT 是什么?** MIT + 商标保护 + 托管规模上限;自部署/内部/个人永久免费
- **多租户谁验证的?** 四探针脚本开源,任何人对生产端点可重跑
- **为什么不是纯开源?** 全源码可得 + \$3.50 复现全链路 + 证据链全公开——开放程度用行为定义,不用标签