

Don't Summarize the Past for a Future You Can't Predict

nautilus-compass · 技术深讲版(30 min)

Chunxiao Wang · 2026-09

github.com/chunxiaox/nautilus-compass

写入 0 LLM 调用 · e2e 42.6% → 75.4% · p95 快 80× · 判官病理学

第一幕 · 问题与立场

你的 agent 正在忘记你

写入时压缩 = 对未来的盲目下注

写入时压缩
压缩与提炼同时发生
信息被冻结在当初那个
模型的认知水平

未来查询
没人知道会被问什么
分布不可知
(今天赌不中明天的题)

× 赌注在结构上就赢不了

而且成本曲线方向反了

LLM 调用恒贵

把便宜的换成昂贵的 = 双输

存储 → 0

市场现状:三大策略,同一个死穴

策略	谁在做	何时做有损决定
压缩	多数 SaaS 记忆层	写入时
提炼/摘要	mem0 / Zep / Letta	写入时
裸读长上下文	直塞 context window	牺牲性能(掉 30-60%)

全部在写入时对未来下注 —— 没有人把宝押在读取端

三不变量:为什么写时压缩必输

1. **未来查询分布不可知** —— 重要性只在被问到的时刻显影。实证:同一份记忆,按题型切换检索粒度, $P@1$ 0.20 $\rightarrow$ 1.00;变的不是记忆,是问题
2. **原文是唯一可重新索引的表示** —— 提炼物被冻结在当初那个 LLM 的认知水平;原文明天可换更好 embedder、可作训练燃料
3. **成本曲线方向反了** —— 存储趋零、LLM 调用恒贵;把便宜的(原文)换成昂贵的(提炼物)是逆成本曲线

第三方背书:不是我们自己说

ICLR 2025 · LongMemEval 基准论文(arXiv 2410.10813)

- §5.2:用 LLM 提炼的摘要/facts 替代原文 → 因信息丢失损害 QA
- Appendix B 人肉研究:ChatGPT 压缩历史时覆写关键信息,Coze 漏记间接提及
- 长上下文直读掉 30-60% → 裸读是死路,记忆层必要性由基准作者论证

第二幕·架构

反架构:写入零智能,读取全智能

nautilus-compass • 反架构:写入零智能,读取全智能

治理

drift 检测(AUC 0.83)· 合约审计 · scoped 多租户 · 判分卫生学

进化

跨 agent 记忆胶囊:验证后写回(reward ≥ 1.0 防毒门)→ 按需继承

写入侧 • 0 LLM 调用

格式

OKF 兼容

存储

原文 verbatim · 本地 BGE-m3
零 LLM · 零上云

读取侧 • 全部智能

召回

6 型路由 → BM25+dense(RRF)· 日期锚定

组装

分题型摘要卡 · 日期时间线

answer

写入:免费、无损、永远 —— 智能全部在读取端

生态定位:从 nautilus 平台长出来的组件

- 起源:nautilus 智涌平台 agent 舰队需要跨 agent 记忆层 → compass 保持 **dogfood**
- 平台 Trinity 三层架构中对应**记忆与治理层**的独立开源形态
- **独立组件,不依赖平台**:本地三条命令完整运行
- 130 天 771 commits,其中 603 由 agent 舰队提交——组织日常跑在上面

写入端决策表

决策	内容	理由
存什么	原文 verbatim(md+frontmatter+ [[链接]])	不变量 2
怎么索引	本地 BGE-m3 dense + BM25 + 日期元数据	三路互补:词面扛标识符/dense 扛语义/日期扛时序
不做什么	零 LLM:不提炼、不建图、不摘要、不上云	不变量 1+3
质量门	胶囊写回需 reward ≥ 1.0	验证过的经验才入库,防跨 agent 复利成毒

架构决策记录:放弃过什么(负结果公开)

被放弃的方案	结果	教训
图数据库 Neo4j + graph rerank	检索 -6.2pt	图边引入噪声;复杂度做减法
cross-encoder reranker	e2e -2pt	嵌入自身排序已更好,叠床架屋
大 K(K=50 vs 20)	无差异	无 reranker 时 K 只加宽 RRF 窗口
小嵌入模型 Qwen3-0.6B	wash(P@5 0.833 vs 0.867)	嵌入质量是地基
LoRA 域适配 embedder	代理指标涨,e2e 平	预注册 +5pt 门没过就不上
abstention gate 主动拒答	误拒 web 92 题(门≤1)	打掉的是噪声不是错误

第三幕·算法解剖

六型分型路由:问题先分类,检索再定粒度

型	全称	策略	基线 → 终局
ssu	single-session-user	turn 级块(滑动窗 2)	0.957 → 0.971
ssp	single-session-preference	turn 级块	0.800 → 0.800
ku	knowledge-update	turn 级块	0.731 → 0.808
ssa	single-session-assistant	摘要卡	0.250 → 0.839
ms	multi-session	摘要卡	0.226 → 0.692
tr	temporal-reasoning	摘要卡+日期时间线	0.158 → 0.624

ssu/ssp/ku 的 context 字节不变 —— 不碰强项,改动集中在三弱型

归因链:42.6 → 75.4,每一步

步	数字(full / 剔除断连)	改动
500 题基线(8/29)	42.6% / —	dense+BM25 RRF(k=60)+日期锚定+四型 utterance context
摘要层 A 臂(9/3)	70.0% / 81.6%	三弱型路由摘要卡;9/2 预注册三态门,三型全过
判官断连重判(9/4)	75.4%(377/500)/ 81.6%	71 题曾被网关故障记错,同判官同 prompt 仅加重试

净 +32.8pt = 方法效应 27.4pt + 测量修正 5.4pt

三口径:同一次跑的三个数字

口径	数字	含义
保守(断连记错)	0.700	下界
重判后(同判官+退避)	0.754	发布口径
干净(剔 71 断连题,n=429)	0.816	上界

只报一个数 = 替听众做决定;三口径并报 = 把决定权还给听众

检索层演进:0.784 → 0.890,赢在路由不赢在嵌入

版本	P@1	增量来源
m3-only(K20 混合)	0.784	与 mem0(0.774)打平——纯基建不赢
+ ssu/ssp 分型路由	0.848	单会话型切 turn 级
+ ku 路由	0.876	知识更新型切 turn 级
+ 日期锚定	0.890	tr P@1 0.83→0.88;P@5 0.978 / MRR 0.929

检索对打:实验设置逐字段

- **同题**:LongMemEval-S 全 500 题,按 question_id join
- **同判据**:retrieval-only 双方;mem0 infer=False (纯检索,不开 LLM 提炼)
- **各用默认嵌入**:我方 BGE-m3 / mem0 复现 vertexai text-embedding-005
- **版本钉死**:mem0ai 2.0.19(8/27 pip 核对 PyPI 最新)
- 结果:P@1 **0.890 vs 0.774**,P@5 **0.978 vs 0.916**,MRR **0.929 vs 0.834**

诚实披露:对方嵌入在部分单会话型更强;我们靠分型路由整体赢。

"同题同判据"成立,"同嵌入"不成立也无需成立 —— 开箱对打才是用户真实场景

第四幕·判官病理学

判官失败 = 资源耗尽:三型 taxonomy

部署中的判官是 $J^*(\theta, B, I)$:知识边界 θ · 输出预算 B · 打分基础设施 I

型	检测信号	retry 可治?	可部署前检出?	分数效应
J-K 知识边界	Δ 探针集	否	是	静默放过错误
J-B 输出预算	截断/空响应率	否	是	塌缩到默认标签
J-C 连接	错误标签率	是	仅运行中	假性错答(下界)

三型机制不同、信号不同、解药不同 —— 混为一谈必然用错药

J-K:数值精度盲区(2,600 次真实 API 调用)

- 双判官族(Kimi k3 / MiniMax-M3),注入数值误差的通过率**随幅度单调下降**:

判官	±0.1%	±1%	±10%
Kimi k3	48%	14%	0%
MiniMax-M3	37%	12%	0%

- 盲区在"事实性要求已写入判分 prompt"的前提下**仍存在**;换更强判官没用(跨族差 ≤ 11 pp)
- 判官能抓的:实体替换/常识错误/文风夸大全部 0% 通过 —— 是数值盲区,不是普遍轻信

J-B:预算饥饿的判官(生产事故 ①)

- reasoning 判官 `max_tokens=4096` 被思考过程吃满,截断输出解析为默认标签
- ent 域 146/211 题(69%)记 0,raw 日志 250 次空响应
- 连续两轮调优被误判为"方法未过门" —— 测量坏了,方法背锅
- 重判(16384/low):web +3.3pt / ent -1.9pt —— 方向相反,不重判就带错发布

解药 = 部署时冒烟:真实尺寸条目上断言判官输出非空可解析

J-C:断连的判官(生产事故 ②)

- 500 题生产跑,71 题(14.2%) 由间歇 403/超时网关后的判官"判分"——中止调用被记为错答
- 整轮重试未清零(新题继续命中)= 随机基础设施故障,非题目绑定
- 失真 5.4pt $\approx$ 被测真实效应(32.8pt)的 1/6
- 中期一次"-20pt 子型回归"事后证实全部是断连误标

基础设施噪声可以吞掉六分之一的被测效应 —— 还能制造幻影回归

Hygiene Protocol P1-P5(成本 $\approx$ 几次 API 调用)

1. **P1 预注册锚与门**:跑数前冻结锚/门/裁决规则,版本化+hash
2. **P2 同判官重判退避**(J-C 解药):只重试打分调用,答案原样复用;仍败的报告不丢弃
3. **P3 多口径披露**:保守/重判后/干净三口径并报;口径不一致本身就是发现
4. **P4 部署冒烟**(J-B 解药):真实条目、非空断言、预算审计、配置变更后重跑
5. **P5 二项噪声带**: $n=30$ 上一题 $=\pm 3.3pt$;带内"回归"推迟到逐题审计

六相 checklist:部署前 Δ 探针+冒烟 / 跑前预注册 / 跑中签名率监控 / 跑后重判+多口径

第五幕·评测版图

五个战场各测什么(组合逻辑)

战场	性质	回答的问题
LME-S e2e 500 题	自建 harness 主场	方法效应:42.6 → 75.4
检索对打 mem0	同题同判据	相对优势:0.890 vs 0.774
LOCOMO-10 客场(n=1986)	换数据集	泛化:0.644 vs 0.592
EverMemBench 第三方榜	别人的卷子	防自吹:44.4-47.3 vs Mem0 37.09 / Zep 39.97 / MemOS 42.55
LME-V2 官方基准(451 题)	社区坐标系	可比性:40.0/38.4(untuned 19.6/12.8)

单一战场都可被质疑;组合的覆盖面难以全部归为"自选有利"

LME-V2:调优记录与判分修正

步	内容	效果
untuned(8/30)	首跑基线	web 19.6 / ent 12.8
刀1 abstention 口径	禁裸 UNKNOWN,引导两条合法得分路线	abstention 组 web 2.8→45.8 / ent 0→83.9
刀2 检索单元升级	空结构行剪枝+轨迹内重排+预算 12k→24k	gold-在场 ent 0.115→0.652(倒挂修复)
d13 判分修正	judge 4096→16384 重判	web 36.7→40.0 / ent 40.3→38.4

attribution:上游官方基准(xiaowu0162/LongMemEval-V2,Di Wu 等)——题目/轨迹归上游,不抢功

官方坐标系里的诚实定位

官方 Small Overall(gpt-5.2 judge + 200k 预算):No retrieval 1.3 / RAG **42.8** / RAG+notes 51.0 / AgentRunbook-R 58.6(26.9s)/ Codex 69.9(177s)/ AgentRunbook-C 74.9(108s)

compass $\approx$ 39.3 —— 与最弱 RAG 基线相当,不是优势

- 差距两结构性来源:预算 24k vs 200k(8.3 $\times$);判分口径(全题 LLM judge vs 程序化为主)
- 我们的差异化:**延迟**(0.165-0.328s vs 26.9s)+ 判分卫生学贡献
- 主攻坚 = 三池设计移植,目标 Small 55-60%(超 AgentRunbook-R)后再上官方榜

第六幕·安全与多租户

三层身份模型 + scoped token

```
user(JWT 身份) → 设备 → agent(scoped token: read:<project> / write:<project>)
```

- 隔离边界 = project 命名空间;header-only 身份(X-User-ID 类)**永久禁止**
—— v0.9 曾有冒充洞(公网可冒充任意用户读写),已改 JWT-only + 五项矩阵验证
- 自助 token 只含持有者自己的空间;缺省 project 显式注入持有者 uid
- 公网自助 token 只见 8 个用户工具(tools/list 17→8),内部工具直调 forbidden

四探针:隔离不是声明,是可重跑的生产事实

探针	断言
P1	A 的 token 读 B 的空间 → forbidden
P2	A 的 token 写 B 的空间 → forbidden
P3	A 的 token 读写 A 自己的空间 → 放行(不误伤)
P4	撤销 token → 下一次调用立即 401

脚本开源([probes.py](#)),任何人对生产端点可重跑 · 发布流程规定 FOUR-GREEN 才发帖

第七幕·价值与收尾

延迟:80× 差距从哪来

p95 延迟 $\approx 80\times$ 差距;把智能放对时刻的自然结果

nautilus-compass
(读取端路由,无 LLM)

$\approx 80\times$

26.9 s

LLM-controller 型
(写入时压缩阵营)

10^{-1}

10^0

10^1

10^2

成本账

- **写入 0 token**: 每条记忆零 LLM 调用 —— 写时提炼方案的按条边际成本, 在这里是零
- **复现成本 $\approx \$3.50$** : LLM $\approx ¥7$ (5M in + 0.5M out, DeepSeek) + T4 spot 8h ¥3.20 + 网络/冷启 $\approx \$1$ · 约 8h 墙钟
- 诚实注记: 竞品每条记忆的写入成本无我方实测(闭源) —— "写入免费" 是我方可验证的事实, 对方的成本不是我方断言

只对自己可验证的事下断言 —— 这条纪律本身就是成本账的一部分

路线图与开放问题(诚实版)

期	事项
发布窗口	hosted beta 邮箱验证门禁 / PyPI 3.1.1 / MCP 目录提交
主攻坚	三池设计移植,目标 LME-V2 Small 55-60%(当前 ~39.3,与最弱 RAG 相当)
工程	嵌入 daemon 并行化(读吞吐 ~5 rps 天花板根因)
待证	进化层 tier 晋升 uplift 三次实测为 0,重测前不动
开放问题	tr 62.4 仍是短板 · J-K prompt 变体消融未做 · 非 reasoning 判官泛化未测 · hosted 外部真实用户案例为零

Demo:跨会话记忆(现场 live)

```
terminal - nautilus-compass (fully local)

$ compass ingest --session s1          "用户周二早上遛狗,狗叫 Momo"
  ✓ stored verbatim · 0 LLM calls · 0.3s

$ compass ingest --session s2          "在学 Rust,目标重写公司数据处理管线"
  ✓ stored verbatim · 0 LLM calls

$ compass ingest --session s3          "每周一例会总被临时取消"
  ✓ stored verbatim · 0 LLM calls

# —— 三周后 · 全新会话 ——
$ compass recall      "What does the user do on Tuesday mornings?"
  → session-1: "周二早上遛狗,狗叫 Momo"      score 0.89
  ✓ cross-session hit · routed retrieval · p95 0.34s
```

三档接入,一个承诺

路径	适合谁	成本
本地三条命令	隐私/成本敏感 · 单机 agent	永久免费,数据不出机器
Hosted beta	快速试用 · 团队	compass.nautilus.social 自助 signup
私有化	组织部署	联系我们

- 写入 0 token · 召回 0 上云 · BGE-m3 本地嵌入
- Modified MIT:自部署/内部/个人永久免费 —— 开放程度用行为定义,不用标签

One developer. 130 days. No cloud required.

dogfood:造它的组织,本身就长在它上面

130


天

771

commits

603

由 agent 舰队提交



nautilus 智涌平台:多 agent 调度 · compass 记忆胶囊:验证过的经验才写回

(备用页)常问问题

- **mem0 自报 94.4% vs 你们 75.4%?** 口径不同不可比;硬对打=同题同判据检索层 +11.6pt
- **嵌入不一样也算对打?** 各用各的默认嵌入=开箱即用对打;对方嵌入部分单会话型更强,我们靠路由整体赢
- **判官是自己请的,分数可信吗?** 正因如此才有判官病理学:三口径并报+重判工具开源+5 次事故全录
- **为什么不是纯开源?** Modified MIT:全源码+\$3.50 复现+四探针可重跑;自部署永久免费

版本与裁剪

- 30 分钟版 = 全部 40 页; **15 分钟版**: 保留第一幕(4 页)+ 算法解剖归因链/对打(4 页)+ 判官三型/断连(3 页)+ 诚实定位(1 页)+ 四探针(1 页)+ 成本账/路线图/demo/收尾(4 页)
- 5 分钟路演 = 用 pitch_deck_20260904.md(19 页发布版)
- 内容正本: whitepaper_20260905.md(白皮书 v1.1)· 数字口径: docs/nautilusmem/SCOREBOARD.md
- 重渲染: `npx @marp-team/marp-cli pitch_deck_deepdive_20260905.md -o <out> --allow-local-files`